

Aprendizado Profundo

Diffusion Models

Professor: Lucas Silveira Kupssinskü

Agenda


- Modelos Geradores (outra vez 😊)
- Visão geral do processo de difusão
- *Encoder*
- *Decoder*
- *ELBO*
- Treinamento
- Reparametrização da função de custo
- Implementação

Modelos Geradores

- O objetivo de um modelo gerador é aprender uma **distribuição de probabilidade** sobre uma variável aleatória $\mathbf{X}$ usando um conjunto de dados observados $\{x^{(i)}\}_{i=1}^N$ com uma densidade de probabilidade $p_X(x)$ parametrizada por θ


Modelos Geradores

- O objetivo de um modelo gerador é aprender uma **distribuição de probabilidade** sobre uma variável aleatória $\mathbf{X}$ usando um conjunto de dados observados $\{x^{(i)}\}_{i=1}^N$ com uma densidade de probabilidade $p_X(x)$ parametrizada por θ
- Já vimos como modelar esse problema com GANs



Modelos Geradores


- O objetivo de um modelo gerador é aprender uma **distribuição de probabilidade** sobre uma variável aleatória $\mathbf{X}$ usando um conjunto de dados observados $\{x^{(i)}\}_{i=1}^N$ com uma densidade de probabilidade $p_X(x)$ parametrizada por θ
- Já vimos como modelar esse problema com *Normalizing Flows*



Modelos Geradores


- O objetivo de um modelo gerador é aprender uma **distribuição de probabilidade** sobre uma variável aleatória $\mathbf{X}$ usando um conjunto de dados observados $\{x^{(i)}\}_{i=1}^N$ com uma densidade de probabilidade $p_X(x)$ parametrizada por θ
- A próxima ideia é:
 - Definir um *encoder* **sem parâmetros** treináveis que degrada uma imagem adicionando ruído gaussiano de maneira sequencial
 - O *decoder* será treinado para retirar o ruído adicionado

Visão Geral - Difusão



- No processo de difusão estamos adicionando ruído a cada passo de modo que após um número suficientemente grande de passos a imagem fica indistinguível do ruído.
- No processo de *denoising* vamos treinar uma rede neural para remover um passo de adição do ruído
- Após o treinamento, podemos gerar novas instâncias de treinamento a partir de z_T

Visão Geral - Difusão



- Vamos ver em detalhes:
 - A difusão (encoder)
 - O denoising (decoder)
 - O treinamento

Difusão

- O processo de difusão ou o processo *forward* mapeia um exemplo x por uma série de etapas intermediárias $z_1, z_2, \dots, z_T$ via adição de ruído

$$z_1 = \sqrt{1 - \beta_1} \cdot x + \sqrt{\beta_1} \cdot \epsilon_1$$

$$z_t = \sqrt{1 - \beta_t} \cdot z_{t-1} + \sqrt{\beta_t} \cdot \epsilon_t \quad \forall t \in 2, 3, \dots, T$$

- Onde ϵ_t denota o ruído amostrado da distribuição normal padrão
- Os hiperparâmetros $\beta_t \in [0, 1]$ são conhecidos coletivamente como *noise schedule* e controlam o quão rápido é o processo de difusão

Difusão

- Podemos descrever z_t de uma outra forma equivalente

$$q(z_1|x) = \text{Norm}_{z_1}[\sqrt{1 - \beta_1} \cdot x, \beta_1 \cdot I]$$

$$q(z_t|z_{t-1}) = \text{Norm}_{z_t}[\sqrt{1 - \beta_t} \cdot z_{t-1}, \beta_t \cdot I] \quad \forall t \in 2, 3, \dots T$$

- Esse processo é uma Cadeia de Markov, visto que z_t depende apenas de z_{t-1}


Difusão

- A distribuição conjunta de todos os latentes é dada por

$$q(z_{1...T}|x) = q(z_1|x) \prod_{t=2}^T q(z_t|z_{t-1})$$


Difusão

Partimos de três instâncias de treinamento diferentes (nessa caso para exemplo são 1d)




Difusão

Conforme os passos de difusão vão sendo aplicados, as instâncias são combinadas com o ruído




Difusão

Após diversas aplicações de ruído a tendência é que a distribuição fique igual a distribuição de ruído



Difusão

Repare que, as instâncias estão aos poucos convergindo para ficar com a distribuição do ruído



Kernel de Difusão

- Como o processo de difusão é probabilístico, temos que realizar várias amostras z_t em um instante t para a mesma instância de treinamento x
 - Contudo esse processo conforme definido anteriormente é sequencial e lento
- Para acelerar a amostragem, vamos tentar definir uma forma fechada para amostrar diretamente um instante t partindo de x $q(z_t|x)$

Kernel de Difusão

- Vamos partir das definições dos latentes z_1 e z_2

$$\begin{aligned}z_1 &= \sqrt{1 - \beta_1} \cdot x + \sqrt{\beta_1} \cdot \epsilon_1 \\z_2 &= \sqrt{1 - \beta_2} \cdot z_1 + \sqrt{\beta_2} \cdot \epsilon_2\end{aligned}$$

- Substituindo z_1 em z_2 temos que

$$z_2 = \sqrt{1 - \beta_2} \cdot (\sqrt{1 - \beta_1} \cdot x + \sqrt{\beta_1} \cdot \epsilon_1) + \sqrt{\beta_2} \cdot \epsilon_2$$

Kernel de Difusão

$$z_2 = \sqrt{1 - \beta_2} \cdot (\sqrt{1 - \beta_1} \cdot x + \sqrt{\beta_1} \cdot \epsilon_1) + \sqrt{\beta_2} \cdot \epsilon_2$$

- Com um pouco de álgebra (e adicionando zero junto de um dos radicais) temos:

$$z_2 = \sqrt{1 - \beta_2} \cdot (\sqrt{1 - \beta_1} \cdot x + \sqrt{1 - (1 - \beta_1)} \cdot \epsilon_1) + \sqrt{\beta_2} \cdot \epsilon_2$$

Kernel de Difusão

$$z_2 = \sqrt{1 - \beta_2} \cdot (\sqrt{1 - \beta_1} \cdot x + \sqrt{\beta_1} \cdot \epsilon_1) + \sqrt{\beta_2} \cdot \epsilon_2$$

- Com um pouco de álgebra (e adicionando zero junto de um dos radicais) temos:

$$z_2 = \sqrt{1 - \beta_2} \cdot (\sqrt{1 - \beta_1} \cdot x + \sqrt{1 - (1 - \beta_1)} \cdot \epsilon_1) + \sqrt{\beta_2} \cdot \epsilon_2$$

$$z_2 = \sqrt{(1 - \beta_2)(1 - \beta_1)} \cdot x + \sqrt{(1 - \beta_2) - (1 - \beta_2)(1 - \beta_1)} \cdot \epsilon_1 + \sqrt{\beta_2} \cdot \epsilon_2$$

Kernel de Difusão

$$z_2 = \sqrt{1 - \beta_2} \cdot (\sqrt{1 - \beta_1} \cdot x + \sqrt{\beta_1} \cdot \epsilon_1) + \sqrt{\beta_2} \cdot \epsilon_2$$

- Com um pouco de álgebra (e adicionando zero junto de um dos radicais) temos:

$$z_2 = \sqrt{1 - \beta_2} \cdot (\sqrt{1 - \beta_1} \cdot x + \sqrt{1 - (1 - \beta_1)} \cdot \epsilon_1) + \sqrt{\beta_2} \cdot \epsilon_2$$

$$z_2 = \sqrt{(1 - \beta_2)(1 - \beta_1)} \cdot x + \sqrt{(1 - \beta_2) - (1 - \beta_2)(1 - \beta_1)} \cdot \epsilon_1 + \sqrt{\beta_2} \cdot \epsilon_2$$

Esse termo é a soma de duas normais com médias zero e desvio padrão $(1 - \beta_2) - (1 - \beta_2)(1 - \beta_1)$ e β_2 respectivamente. O resultado dessa soma é uma variável aleatória que também segue a distribuição normal com média zero, mas com o desvio padrão igual a soma dos desvios padrões.

Kernel de Difusão

$$z_2 = \sqrt{(1 - \beta_2)(1 - \beta_1)} \cdot x + \sqrt{1 - (1 - \beta_2)(1 - \beta_1)} \cdot \epsilon$$

Podemos seguir fazendo esse processo para derivar expressões para todos os z_t

$$z_t = \sqrt{\alpha_t} \cdot x + \sqrt{1 - \alpha_t} \cdot \epsilon$$
$$\alpha_t = \prod_{s=1}^t 1 - \beta_s$$

Kernel de Difusão


- Ou podemos escrever na forma probabilística

$$q(z_t|x) = \text{Norm}_{z_t}[\sqrt{\alpha_t} \cdot x, \sqrt{1 - \alpha_t} \cdot I], \alpha_t = \prod_{s=1}^t 1 - \beta_s$$

- Dessa forma é fácil gerar diretamente instâncias do latente em um instante t qualquer z_t

Kernel de Difusão

Repare que, um mesmo x^* pode ter diversas trajetórias no processo de difusão, com o kernel de difusão que projetamos agora, conseguimos amostrar diretamente o resultado da aplicação de t passos de difusão



Probabilidade Marginal $q(z_t)$

- Usando a probabilidade conjunta $q(z_{t...1}, x)$ é possível marginalizar a distribuição de probabilidade $q(z_t)$ para um instante t qualquer

$$q(z_t) = \int \int q(z_{t...1}, x) dz_{1...t-1} dx$$

Probabilidade Marginal $q(z_t)$

- Usando a probabilidade conjunta $q(z_{t...1}, x)$ é possível marginalizar a distribuição de probabilidade $q(z_t)$ para um instante t qualquer

$$q(z_t) = \int \int q(z_{t...1}, x) dz_{1...t-1} dx$$

$$q(z_t) = \int \int q(z_{t...1}|x)p(x) dz_{1...t-1} dx$$

Probabilidade Marginal $q(z_t)$

- Usando a probabilidade conjunta $q(z_{t...1}, x)$ é possível marginalizar a distribuição de probabilidade $q(z_t)$ para um instante t qualquer

$$q(z_t) = \int \int q(z_{t...1}, x) dz_{1...t-1} dx$$

$$q(z_t) = \int \int \boxed{q(z_{t...1}|x)} p(x) dz_{1...t-1} dx$$

Aplicando o kernel de difusão conseguimos simplificar a expressão

$$q(z_t) = \int q(z_t|x) p(x) dx$$

Probabilidade Marginal $q(z_t)$

- Usando a probabilidade conjunta $q(z_{t...1}, x)$ é possível marginalizar a distribuição de probabilidade $q(z_t)$ para um instante t qualquer

$$q(z_t) = \int \int q(z_{t...1}, x) dz_{1...t-1} dx$$

$$q(z_t) = \int \int q(z_{t...1}|x)p(x) dz_{1...t-1} dx$$

$$q(z_t) = \int q(z_t|x) \boxed{p(x)} dx$$

Problema: Não conhecemos a distribuição original dos dados $p(x)$, logo não conseguimos uma expressão fechada para esse termo.

Distribuição Condicional $q(z_{t-1}|z_t)$

- Anteriormente conseguimos definir o processo de difusão via $q(z_t|z_{t-1})$, para descobrir a probabilidade condicional do processo de denoising podemos aplicar o **Teorema de Bayes**

$$q(z_{t-1}|z_t) = \frac{q(z_t|z_{t-1})q(z_{t-1})}{q(z_t)}$$

Distribuição Condicional $q(z_{t-1}|z_t)$


- Anteriormente conseguimos definir o processo de difusão via $q(z_t|z_{t-1})$, para descobrir a probabilidade condicional do processo de denoising podemos aplicar o **Teorema de Bayes**

$$q(z_{t-1}|z_t) = \frac{q(z_t|z_{t-1})q(z_{t-1})}{q(z_t)}$$

Problema: $q(z_{t-1})$ não é tratável
(mesmo caso apresentado
anteriormente).

Distribuição Condicional $q(z_{t-1}|z_t)$

$$q(z_{t-1}|z_t) = \frac{q(z_t|z_{t-1})q(z_{t-1})}{q(z_t)}$$



Distribuição condicional da difusão

- Adicionando o dado original x como uma evidência a regra de bayes conseguimos gerar a distribuição condicional da difusão

$$q(z_{t-1}|z_t, x) = \frac{q(z_t|z_{t-1}, x)q(z_{t-1}|x)}{q(z_t|x)}$$

Distribuição condicional da difusão

- Adicionando o dado original x como uma evidência a regra de bayes conseguimos gerar a distribuição condicional da difusão

$$q(z_{t-1}|z_t, x) = \frac{q(z_t|z_{t-1}, x)q(z_{t-1}|x)}{q(z_t|x)}$$

Como a difusão é um processo de Markov $q(z_t|z_{t-1}) = q(z_t|z_{t-1}, x)$

$$\propto q(z_t|z_{t-1})q(z_{t-1}|x)$$

Ao retirar o denominador a igualdade vira uma proporcionalidade

Distribuição condicional da difusão

- Adicionando o dado original x como uma evidência a regra de bayes conseguimos gerar a distribuição condicional da difusão

$$\propto q(z_t|z_{t-1})q(z_{t-1}|x)$$

$$= \text{Norm}_{z_t}[\sqrt{1 - \beta_t} \cdot z_{t-1}, \beta_t I] \text{Norm}_{z_{t-1}}[\sqrt{\alpha_{t-1}} \cdot x, (1 - \alpha_{t-1})I]$$

Substituindo ambos termos por suas respectivas normais

Distribuição condicional da difusão

Usando a formula para mudança de variável em gaussianas e usando o fato que o produto de duas funções de densidade gaussianas é também uma pdf gaussiana temos:

$$q(z_{t-1}|z_t, x) = \frac{q(z_t|z_{t-1}, x)q(z_{t-1}|x)}{q(z_t|x)}$$

$$\propto q(z_t|z_{t-1})q(z_{t-1}|x)$$

$$= \text{Norm}_{z_t}[\sqrt{1 - \beta_t} \cdot z_{t-1}, \beta_t I] \text{Norm}_{z_{t-1}}[\sqrt{\alpha_{t-1}} \cdot x, (1 - \alpha_{t-1})I]$$

$$q(z_{t-1}|z_t, x) = \text{Norm}_{z_{t-1}} \left[\frac{(1 - \alpha_{t-1})}{1 - \alpha_t} \sqrt{1 - \beta_t} z_t + \frac{\sqrt{\alpha_{t-1}} \beta_t}{1 - \alpha_t} x, \frac{\beta_t (1 - \alpha_{t-1})}{1 - \alpha_t} I \right]$$

Decoder

- O aprendizado do processo de difusão está todo no decoder (processo reverso ou processo de *denoising*)

$$z_t \rightarrow z_{t-1} \rightarrow \cdots \rightarrow z_1 \rightarrow x$$

- A distribuição reversa real $q(z_{t-1}|z_t)$ é uma distribuição complexa e potencialmente multimodal que depende da distribuição dos dados
- Na prática, aproximamos essas distribuições como normais

$$p(z_t) = \text{Norm}_{z_t}[0, I]$$

$$p(z_{t-1}|z_t, \theta_t) = \text{Norm}_{z_{t-1}}[f_t[z_t, \theta_t], \sigma_t^2 I]$$

$$p(x|z_1, \theta_1) = \text{Norm}_x[f_1[z_1, \theta_1], \sigma_1^2 I]$$

Se o número de passos de difusão for grande e β for próximo de 0 essas aproximações são razoáveis

Treinamento

- Ideia: Encontrar os parâmetros que maximizam a verossimilhança dos dados $p(x|\theta_{1...T})$

$$p(x, z_{1...T}|\theta_{1...T}) = p(x|z_1, \theta_1) \prod_{t=2}^T p(z_{t-1}|z_t, \theta_t) \cdot p(z_t)$$

Treinamento

- Ideia: Encontrar os parâmetros que maximizam a verossimilhança dos dados $p(x|\theta_{1...T})$

$$p(x, z_{1...T}|\theta_{1...T}) = p(x|z_1, \theta_1) \prod_{t=2}^T p(z_{t-1}|z_t, \theta_t) \cdot p(z_t)$$

- Marginalizando todas as variáveis latentes z_t temos

$$p(x|\theta_{1...T}) = \int p(x, z_{1...T}|\theta_{1...T}) dz_{1...T}$$

$$\theta_{1...T} = \operatorname{argmax}_{\theta_{1...T}} \left[\sum_{i=1}^N \log[p(x^{(i)}|\theta_{1...T})] \right]$$

Treinamento

- Ideia: Encontrar os parâmetros que maximizam a verossimilhança dos dados $p(x|\theta_{1...T})$

$$p(x, z_{1...T}|\theta_{1...T}) = p(x|z_1, \theta_1) \prod_{t=2}^T p(z_{t-1}|z_t, \theta_t) \cdot p(z_t)$$

- Marginalizando todas as variáveis latentes z_t temos

$$p(x|\theta_{1...T}) = \int p(x, z_{1...T}|\theta_{1...T}) dz_{1...T}$$

$$\theta_{1...T} = \operatorname{argmax}_{\theta_{1...T}} \left[\sum_{i=1}^N \log[p(x^{(i)}|\theta_{1...T})] \right]$$

Como essa probabilidade é intratável, não conseguimos otimizar diretamente essa expressão

A alternativa é usar a Desigualdade de Jensen e maximizar o ELBO

Evidence Lower Bound (ELBO)

$$\begin{aligned}\log[p(x^{(i)}|\theta_{1...T})] &= \log \int p(x, z_{1...T}|\theta_{1...T})dz_{1...T} \\ &= \log \int \frac{p(x, z_{1...T}|\theta_{1...T})dz_{1...T}}{q(z_{1...T}|x)} q(z_{1...T}|x) \\ &\geq \int q(z_{1...T}|x) \log \left[\frac{p(x, z_{1...T}|\theta_{1...T})dz_{1...T}}{q(z_{1...T}|x)} \right]\end{aligned}$$

Evidence Lower Bound (ELBO)

$$\begin{aligned}\log[p(x^{(i)}|\theta_{1...T})] &= \log \int p(x, z_{1...T}|\theta_{1...T})dz_{1...T} \\ &= \log \int \frac{p(x, z_{1...T}|\theta_{1...T})dz_{1...T}}{q(z_{1...T}|x)} q(z_{1...T}|x) \\ &\geq \int q(z_{1...T}|x) \log \left[\frac{p(x, z_{1...T}|\theta_{1...T})dz_{1...T}}{q(z_{1...T}|x)} \right]\end{aligned}$$

Vamos trabalhar nesse termo

ELBO

$$\log \left[\frac{p(x, z_{1...T} | \theta_{1...T}) dz_{1...T}}{q(z_{1...T} | x)} \right]$$

$$p(x, z_{1...T} | \theta_{1...T}) = p(x | z_1, \theta_1) \prod_{t=2}^T p(z_{t-1} | z_t, \theta_t) \cdot p(z_T)$$

$$q(z_{1...T} | x) = q(z_1 | x) \prod_{t=2}^T q(z_t | z_{t-1})$$

ELBO

$$\log \left[\frac{p(x|z_1, \theta_1) \prod_{t=2}^T p(z_{t-1}|z_t, \theta_t) \cdot p(z_T)}{q(z_1|x) \prod_{t=2}^T q(z_t|z_{t-1})} \right]$$

$$= \log \left[\frac{p(x|z_1, \theta_1)}{q(z_1|x)} \right] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1}|z_t, \theta_t)}{\prod_{t=2}^T q(z_t|z_{t-1})} \right] + \log[p(z_T)]$$

$$q(z_t|z_{t-1}) = q(z_t|z_{t-1}, \mathbf{x}) = \frac{q(z_{t-1}|\mathbf{z}_t, \mathbf{x})q(\mathbf{z}_t|\mathbf{x})}{q(z_{t-1}|\mathbf{x})}$$

ELBO

$$\log \left[\frac{p(x|z_1, \theta_1) \prod_{t=2}^T p(z_{t-1}|z_t, \theta_t) \cdot p(z_T)}{q(z_1|x) \prod_{t=2}^T q(z_t|z_{t-1})} \right]$$

$$= \log \left[\frac{p(x|z_1, \theta_1)}{q(z_1|x)} \right] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1}|z_t, \theta_t)}{\prod_{t=2}^T q(z_t|z_{t-1})} \right] + \log[p(z_T)]$$

$$= \log \left[\frac{p(x|z_1, \theta_1)}{q(z_1|x)} \right] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1}|z_t, \theta_t) \cdot q(z_{t-1}|x)}{\prod_{t=2}^T q(z_{t-1}|z_t, x) \cdot q(z_t|x)} \right] + \log[p(z_T)]$$

ELBO

$$= \log \left[\frac{p(x|z_1, \theta_1)}{q(z_1|x)} \right] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1}|z_t, \theta_t) \cdot q(z_{t-1}|x)}{\prod_{t=2}^T q(z_{t-1}|z_t, x) \cdot q(z_t|x)} \right] + \log[p(z_T)]$$

$$q(z_1|x) \cdot q(z_2|x) \cdot q(z_3|x) \dots q(z_{T-1}|x)$$

$$q(z_2|x) \cdot q(z_3|x) \dots q(z_{T-1}|x) \cdot q(z_T|x)$$

ELBO

$$= \log \left[\frac{p(x|z_1, \theta_1)}{q(z_1|x)} \right] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1}|z_t, \theta_t) \cdot q(z_{t-1}|x)}{\prod_{t=2}^T q(z_{t-1}|z_t, x) \cdot q(z_t|x)} \right] + \log[p(z_T)]$$

$$q(z_1|x) \cdot \cancel{q(z_2|x)} \cdot \cancel{q(z_3|x)} \dots \cancel{q(z_{T-1}|x)}$$

$$\cancel{q(z_2|x)} \cdot \cancel{q(z_3|x)} \dots \cancel{q(z_{T-1}|x)} \cdot q(z_T|x)$$

ELBO

$$= \log \left[\frac{p(x|z_1, \theta_1)}{q(z_1|x)} \right] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1}|z_t, \theta_t)}{\prod_{t=2}^T q(z_{t-1}|z_t, x)} \right] + \frac{\log[q(z_1|x)]}{\log[q(z_T|x)]} + \log[p(z_T)]$$

$$= \log \left[\frac{p(x|z_1, \theta_1) q(z_1|x)}{q(z_1|x)} \right] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1}|z_t, \theta_t)}{\prod_{t=2}^T q(z_{t-1}|z_t, x)} \right] + \log \left[\frac{p(z_T)}{q(z_T|x)} \right]$$

$$= \log[p(x|z_1, \theta_1)] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1}|z_t, \theta_t)}{\prod_{t=2}^T q(z_{t-1}|z_t, x)} \right] + \log \left[\frac{p(z_T)}{q(z_T|x)} \right]$$

ELBO

$$= \log \left[\frac{p(x|z_1, \theta_1)}{q(z_1|x)} \right] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1}|z_t, \theta_t)}{\prod_{t=2}^T q(z_{t-1}|z_t, x)} \right] + \frac{\log[q(z_1|x)]}{\log[q(z_T|x)]} + \log[p(z_T)]$$

$$= \log \left[\frac{p(x|z_1, \theta_1) q(z_1|x)}{q(z_1|x)} \right] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1}|z_t, \theta_t)}{\prod_{t=2}^T q(z_{t-1}|z_t, x)} \right] + \log \left[\frac{p(z_T)}{q(z_T|x)} \right]$$

$$= \log[p(x|z_1, \theta_1)] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1}|z_t, \theta_t)}{\prod_{t=2}^T q(z_{t-1}|z_t, x)} \right] + \log \left[\frac{p(z_T)}{q(z_T|x)} \right] \overset{0}{\cancel{}}$$

ELBO

$$\log \left[\frac{p(x, z_{1...T} | \theta_{1...T}) dz_{1...T}}{q(z_{1...T} | x)} \right] \approx \log[p(x | z_1, \theta_1)] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1} | z_t, \theta_t)}{\prod_{t=2}^T q(z_{t-1} | z_t, x)} \right]$$

$$\text{ELBO}[\theta_{1...T}] = \int q(z_{1...T} | x) \log \left[\frac{p(x, z_{1...T} | \theta_{1...T}) dz_{1...T}}{q(z_{1...T} | x)} \right] dz_{1...T}$$

ELBO

$$\log \left[\frac{p(x, z_{1...T} | \theta_{1...T}) dz_{1...T}}{q(z_{1...T} | x)} \right] \approx \log[p(x | z_1, \theta_1)] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1} | z_t, \theta_t)}{\prod_{t=2}^T q(z_{t-1} | z_t, x)} \right]$$

$$\text{ELBO}[\theta_{1...T}] = \int q(z_{1...T} | x) \left[\log[p(x | z_1, \theta_1)] + \sum_{t=2}^T \log \left[\frac{p(z_{t-1} | z_t, \theta_t)}{q(z_{t-1} | z_t, x)} \right] \right] dz_{1...T}$$

ELBO

$$\log \left[\frac{p(x, z_{1...T} | \theta_{1...T}) dz_{1...T}}{q(z_{1...T} | x)} \right] \approx \log[p(x | z_1, \theta_1)] + \log \left[\frac{\prod_{t=2}^T p(z_{t-1} | z_t, \theta_t)}{\prod_{t=2}^T q(z_{t-1} | z_t, x)} \right]$$

$$\text{ELBO}[\theta_{1...T}] = \int q(z_{1...T} | x) \left[\log[p(x | z_1, \theta_1)] + \sum_{t=2}^T \log \left[\frac{p(z_{t-1} | z_t, \theta_t)}{q(z_{t-1} | z_t, x)} \right] \right] dz_{1...T}$$

$$\begin{aligned} & \text{ELBO}[\theta_{1...T}] \\ &= \mathbb{E}_{q(z_1 | x)} [\log[p(x | z_1, \theta_1)]] - \sum_{t=2}^T \mathbb{E}_{q(z_t | x)} D_{KL}[[q(z_{t-1} | z_t, x)] || p(z_{t-1} | z_t, \theta_t)] \end{aligned}$$

ELBO

$$\text{ELBO}[\theta_{1...T}]$$

$$= \mathbb{E}_{q(z_1|x)}[\log[p(x|z_1, \theta_1)]] - \sum_{t=2}^T \mathbb{E}_{q(z_t|x)} D_{KL}[[q(z_{t-1}|z_t, x)]||p(z_{t-1}|z_t, \theta_t)]]$$
$$p(x|z_1, \theta_1) = \text{Norm}_x[f_1[z_1, \theta_1], \sigma_1^2 I]$$

ELBO

$$\text{ELBO}[\theta_{1...T}]$$

$$= \mathbb{E}_{q(z_1|x)}[\log[p(x|z_1, \theta_1)]] - \sum_{t=2}^T \mathbb{E}_{q(z_t|x)} D_{KL} [p(z_{t-1}|z_t, x) || p(z_{t-1}|z_t, \theta_t)]$$

$$q(z_{t-1}|z_t, x) = \text{Norm}_{z_{t-1}} \left[\frac{(1 - \alpha_{t-1})}{1 - \alpha_t} \sqrt{1 - \beta_t} z_t + \frac{\sqrt{\alpha_{t-1} \beta_t}}{1 - \alpha_t} x, \frac{\beta_t (1 - \alpha_{t-1})}{1 - \alpha_t} I \right]$$

ELBO

$$\text{ELBO}[\theta_{1...T}]$$

$$= \mathbb{E}_{q(z_1|x)}[\log[p(x|z_1, \theta_1)]] - \sum_{t=2}^T \mathbb{E}_{q(z_t|x)} D_{KL}[p(z_{t-1}|z_t, x) | p(z_{t-1}|z_t, \theta_t)]$$

$$q(z_{t-1}|z_t, x) = \text{Norm}_{z_{t-1}} \left[\frac{(1 - \alpha_{t-1})}{1 - \alpha_t} \sqrt{1 - \beta_t} z_t + \frac{\sqrt{\alpha_{t-1} \beta_t}}{1 - \alpha_t} x, \frac{\beta_t (1 - \alpha_{t-1})}{1 - \alpha_t} I \right]$$

$$p(z_{t-1}|z_t, \theta_t) = \text{Norm}_{z_{t-1}} [f_t[z_t, \theta_t], \sigma_t^2 I]$$

ELBO

$$\text{ELBO}[\theta_{1...T}]$$

A KL Divergence entre duas distribuições normais tem uma expressão fechada

$$\begin{aligned} &= \mathbb{E}_{q(z_1|x)}[\log[p(x|z_1, \theta_1)]] - \sum_{t=2}^T \mathbb{E}_{q(z_t|x)} [D_{KL}[p(z_{t-1}|z_t, x) || p(z_{t-1}|z_t, \theta_t)]] \\ &\quad \mathbb{E}_{q(z_t|x)} D_{KL}[p(z_{t-1}|z_t, x) || p(z_{t-1}|z_t, \theta_t)] \\ &= \frac{1}{2\sigma_t^2} \left| \frac{(1 - \alpha_{t-1})}{1 - \alpha_t} \sqrt{1 - \beta_t} z_t + \frac{\sqrt{\alpha_{t-1}\beta_t}}{1 - \alpha_t} x - f_t[z_t, \theta_t] \right|^2 \end{aligned}$$

Diffusion Loss Function

$$\begin{aligned} & L[\theta_{1:T}] \\ &= \sum_{i=1}^T (-\log[\text{Norm}_x[f_1[z_1, \theta_1], \sigma_1^2 I]]) \\ &+ \sum_{t=2}^T \frac{1}{2\sigma_t^2} \left| \frac{(1 - \alpha_{t-1})}{1 - \alpha_t} \sqrt{1 - \beta_t} z_t + \frac{\sqrt{\alpha_{t-1}\beta_t}}{1 - \alpha_t} x - f_t[z_t, \theta_t] \right|^2 \end{aligned}$$

Diffusion Loss Function

$$\begin{aligned} L[\theta_{1...T}] &= \sum_{t=1}^T (-\log[\text{Norm}_x[f_1[z_1, \theta_1], \sigma_1^2 I]]) \\ &+ \sum_{t=2}^T \frac{1}{2\sigma_t^2} \left| \frac{(1 - \alpha_{t-1})}{1 - \alpha_t} \sqrt{1 - \beta_t} z_t + \frac{\sqrt{\alpha_{t-1}\beta_t}}{1 - \alpha_t} x - f_t[z_t, \theta_t] \right|^2 \end{aligned}$$

Termo de
reconstrução

Termo que avalia o quão distante
a predição está do valor obtido em
um timestep t

Porém...

- Depois de treinar diversos modelos difusores que tentavam descobrir diretamente a imagem, percebeu-se empiricamente que os resultados eram melhores ao usar a rede para estimar o ruído
 - Vamos reparametrizar a função de custo e substituir por uma rede que estima o ruído

Reparametrizando a loss

- O processo de difusão era definido por

$$z_t = \sqrt{a_t} \cdot x + \sqrt{1 - a_t} \cdot \epsilon$$

- Isolando o x temos

$$x = \frac{z_t}{\sqrt{a_t}} - \frac{\sqrt{1 - a_t}}{\sqrt{a_t}} \cdot \epsilon$$

Agora precisamos usar essa definição de x na nossa loss

Reparametrizando a loss

$$\begin{aligned} L[\theta_{1...T}] &= \sum_{i=1}^T (-\log[\text{Norm}_x[f_1[z_1, \theta_1], \sigma_1^2 I]]) \\ &+ \sum_{t=2}^T \frac{1}{2\sigma_t^2} \left| \frac{(1 - \alpha_{t-1})}{1 - \alpha_t} \sqrt{1 - \beta_t} z_t + \frac{\sqrt{\alpha_{t-1} \beta_t}}{1 - \alpha_t} \boxed{x} - f_t[z_t, \theta_t] \right|^2 \end{aligned}$$

$$\boxed{x = \frac{z_t}{\sqrt{\alpha_t}} - \frac{\sqrt{1 - \alpha_t}}{\sqrt{\alpha_t}} \cdot \epsilon}$$

$$\begin{aligned}
& \frac{(1 - \alpha_{t-1})}{1 - \alpha_t} \sqrt{1 - \beta_t} \mathbf{z}_t + \frac{\sqrt{\alpha_{t-1}} \beta_t}{1 - \alpha_t} \mathbf{x} \\
&= \frac{(1 - \alpha_{t-1})}{1 - \alpha_t} \sqrt{1 - \beta_t} \mathbf{z}_t + \frac{\sqrt{\alpha_{t-1}} \beta_t}{1 - \alpha_t} \left(\frac{1}{\sqrt{\alpha_t}} \mathbf{z}_t - \frac{\sqrt{1 - \alpha_t}}{\sqrt{\alpha_t}} \boldsymbol{\epsilon} \right) \\
&= \frac{(1 - \alpha_{t-1})}{1 - \alpha_t} \sqrt{1 - \beta_t} \mathbf{z}_t + \frac{\beta_t}{1 - \alpha_t} \left(\frac{1}{\sqrt{1 - \beta_t}} \mathbf{z}_t - \frac{\sqrt{1 - \alpha_t}}{\sqrt{1 - \beta_t}} \boldsymbol{\epsilon} \right), \\
&= \left(\frac{(1 - \alpha_{t-1}) \sqrt{1 - \beta_t}}{1 - \alpha_t} + \frac{\beta_t}{(1 - \alpha_t) \sqrt{1 - \beta_t}} \right) \mathbf{z}_t - \frac{\beta_t}{\sqrt{1 - \alpha_t} \sqrt{1 - \beta_t}} \boldsymbol{\epsilon} \\
&= \left(\frac{(1 - \alpha_{t-1})(1 - \beta_t)}{(1 - \alpha_t) \sqrt{1 - \beta_t}} + \frac{\beta_t}{(1 - \alpha_t) \sqrt{1 - \beta_t}} \right) \mathbf{z}_t - \frac{\beta_t}{\sqrt{1 - \alpha_t} \sqrt{1 - \beta_t}} \boldsymbol{\epsilon} \\
&= \frac{(1 - \alpha_{t-1})(1 - \beta_t) + \beta_t}{(1 - \alpha_t) \sqrt{1 - \beta_t}} \mathbf{z}_t - \frac{\beta_t}{\sqrt{1 - \alpha_t} \sqrt{1 - \beta_t}} \boldsymbol{\epsilon} \\
&= \frac{1 - \alpha_t}{(1 - \alpha_t) \sqrt{1 - \beta_t}} \mathbf{z}_t - \frac{\beta_t}{\sqrt{1 - \alpha_t} \sqrt{1 - \beta_t}} \boldsymbol{\epsilon} \\
&= \frac{1}{\sqrt{1 - \beta_t}} \mathbf{z}_t - \frac{\beta_t}{\sqrt{1 - \alpha_t} \sqrt{1 - \beta_t}} \boldsymbol{\epsilon},
\end{aligned}$$

Reparametrizando a rede

$$\begin{aligned} L[\theta_{1...T}] &= \sum_{i=1}^T (-\log[\text{Norm}_x[f_1[z_1, \theta_1], \sigma_1^2 I]]) \\ &+ \sum_{t=2}^T \frac{1}{2\sigma_t^2} \left| \left(\frac{1}{\sqrt{1-\beta_t}} z_t - \frac{\beta_t}{\sqrt{1-a_t}\sqrt{1-\beta_t}} \epsilon_t \right) - f_t[z_t, \theta_t] \right|^2 \end{aligned}$$

$$f_t[z_t, \theta_t] = \frac{1}{\sqrt{1-\beta_t}} z_t - \frac{\beta_t}{\sqrt{1-a_t}\sqrt{1-\beta_t}} g_t[z_t, \theta_t]$$

Reparametrizando a rede

$$\begin{aligned} & L[\theta_{1 \dots T}] \\ &= \sum_{i=1}^T (-\log[\text{Norm}_x[f_1[z_1, \theta_1], \sigma_1^2 I]]) \\ &+ \sum_{t=2}^T \frac{1}{2\sigma_t^2} \left\| \left(\frac{1}{\sqrt{1-\beta_t}} z_t - \frac{\beta_t}{\sqrt{1-a_t}\sqrt{1-\beta_t}} \epsilon_t \right) - \left(\frac{1}{\sqrt{1-\beta_t}} z_t - \frac{\beta_t}{\sqrt{1-a_t}\sqrt{1-\beta_t}} g_t[z_t, \theta_t] \right) \right\|^2 \end{aligned}$$

Reparametrizando a rede

$$L[\theta_{1...T}] = \sum_{i=1}^I (-\log[\text{Norm}_x[f_1[z_1, \theta_1], \sigma_1^2 I]]) + \sum_{t=2}^T \frac{\beta_t^2}{(1 - a_t)(1 - \beta_t)2\sigma_t^2} |(g_t[z_t, \theta_t] - \epsilon_t)|^2$$

Reparametrizando a rede

$$L[\theta_{1...T}] = \sum_{i=1}^I \sum_{t=2}^T \frac{\beta_t^2}{(1 - a_t)(1 - \beta_t)2\sigma_t^2} |(g_t[z_t, \theta_t] - \epsilon_t)|^2$$

Como queremos otimizar os pesos, podemos abandonar as constantes multiplicativas

Reparametrizando a rede

$$L[\theta_{1...T}] = \sum_{i=1}^I \sum_{t=2}^T \frac{\beta_t^2}{(1 - a_t)(1 - \beta_t)2\sigma_t^2} |(g_t[z_t, \theta_t] - \epsilon_t)|^2$$

Como queremos otimizar os pesos, podemos abandonar as constantes multiplicativas

Reparametrizando a rede

$$L[\theta_{1...T}] = \sum_{i=1}^I \sum_{t=2}^T |(g_t[z_t, \theta_t] - \epsilon_t)|^2$$

$$= \sum_{i=1}^I \sum_{t=2}^T |(g_t[\sqrt{a_t} \cdot x + \sqrt{1 - a_t} \cdot \epsilon_t, \theta_t] - \epsilon_t)|^2$$

Essa é a função de custo do modelo difusor

Treinamento

Algorithm 18.1: Diffusion model training

Input: Training data $\mathbf{x}$

Output: Model parameters ϕ_t

repeat

 for $i \in \mathcal{B}$ do // For every training example index in batch

$t \sim \text{Uniform}[1, \dots, T]$ // Sample random timestep

$\epsilon \sim \text{Norm}[\mathbf{0}, \mathbf{I}]$ // Sample noise

$\ell_i = \left\| \mathbf{g}_t \left[\sqrt{\alpha_t} \mathbf{x}_i + \sqrt{1 - \alpha_t} \epsilon, \phi_t \right] - \epsilon \right\|^2$ // Compute individual loss

 Accumulate losses for batch and take gradient step

until converged

Amostragem

Algorithm 18.2: Sampling

Input: Model, $\mathbf{g}_t[\bullet, \phi_t]$

Output: Sample, $\mathbf{x}$

$\mathbf{z}_T \sim \text{Norm}_{\mathbf{z}}[\mathbf{0}, \mathbf{I}]$ // Sample last latent variable

for $t = T \dots 2$ **do**


$\hat{\mathbf{z}}_{t-1} = \frac{1}{\sqrt{1-\beta_t}}\mathbf{z}_t - \frac{\beta_t}{\sqrt{1-\alpha_t}\sqrt{1-\beta_t}}\mathbf{g}_t[\mathbf{z}_t, \phi_t]$ // Predict previous latent variable

$\epsilon \sim \text{Norm}_{\epsilon}[\mathbf{0}, \mathbf{I}]$ // Draw new noise vector

$\mathbf{z}_{t-1} = \hat{\mathbf{z}}_{t-1} + \sigma_t\epsilon$ // Add noise to previous latent variable

$\mathbf{x} = \frac{1}{\sqrt{1-\beta_1}}\mathbf{z}_1 - \frac{\beta_1}{\sqrt{1-\alpha_1}\sqrt{1-\beta_1}}\mathbf{g}_1[\mathbf{z}_1, \phi_1]$ // Generate sample from $\mathbf{z}_1$ without noise

Modelo para estimar ϵ_t



Classifier-Free Diffusion Guidance

- É comum adicionar uma informação condicionante no processo de geração da imagem
 - Pode parecer contraintuitivo, contudo adicionar informações referentes a classe que estamos querendo utilizar para a geração auxilia no processo e gera imagens com maior qualidade
- O treinamento condicionado normalmente é feito adicionando algum tipo de *embedding* da classe a U-Net
 - Por exemplo os *embeddings* de um BERT sobre a descrição da imagem

Referências

- Capítulo 18 – Understanding Deep Learning – Simon J. Prince
- HO, Jonathan; JAIN, Ajay; ABBEEL, Pieter. Denoising diffusion probabilistic models. **Advances in neural information processing systems**, v. 33, p. 6840-6851, 2020.
- HO, Jonathan; SALIMANS, Tim. Classifier-free diffusion guidance. **arXiv preprint arXiv:2207.12598**, 2022.