Aprendizado Profundo

PyTorch Lightning e Monitoramento de Experimentos

Professor: Lucas Silveira Kupssinskü

- PyTorch puro oferece grande flexibilidade
- Por consequência, é comum encontrarmos códigos confusos e sem padronização
- Uma alternativa é usar o PyTorch Lightning
 - Perdemos em:
 - flexibilidade
 - Ganhamos em:
 - Menos código boilerplate
 - Código mais padronizado

- Temos dois objetos importantíssimos no Lightning
 - LightningModule
 - Trainer
- A lógica do Lightning é implementar as funções pré-determinadas e adicionar comportamento customizado via *callbacks*

- LightningModule
 - É uma extensão do torch.nn.Module
 - Organiza o código PyTorch em diversos métodos
 - __init__ usado para definir a inicialização
 - forward() usado para definir o forward pass do modelo
 - training_step() usado para definir um passo de treinamento, deve retornar a loss
 - validation_step usado para definir um passo de validação
 - test_step() usado para definir o teste
 - configure_optimizers usado para definir o otimizador do modelo

- Trainer
 - É usado para gerenciar o loop de treino e validação
 - Organiza as chamadas do seu LightningModule

Você escreve isso

O Trainer executa isso

```
# enable grads
torch.set_grad_enabled(True)
losses = []
for batch in train_dataloader:
    # calls hooks like this one
    on_train_batch_start()

# train step
loss = training_step(batch)

# clear gradients
optimizer.zero_grad()

# backward
loss.backward()

# update parameters
optimizer.step()
losses.append(loss)
```

```
def create dataloaders(
   data dir: str,
   batch size: int,
   num workers: int
):
   training_data = datasets.MNIST(
        root=data dir,
        train=True,
        download=True,
        transform=ToTensor(),
   test data = datasets.MNIST(
        root=data dir,
        train=False,
        download=True,
        transform=ToTensor(),
   train dataloader = DataLoader(
        training data,
        batch size=batch size,
        shuffle=True,
        num workers=num workers,
        pin memory=True,
        persistent workers=True)
   test dataloader = DataLoader(
        test data,
        batch size=batch size,
        shuffle=False)
   return train dataloader, test dataloader
```

```
class MNISTDataModule(L.LightningDataModule):
  def train_dataloader(self):
     return DataLoader(
        self.train_dataset,
        batch_size=self.batch_size,
        num_workers=self.num_workers,
        pin_memory=True,
        persistent_workers=True,
        shuffle=True,
  def val_dataloader(self):
     return DataLoader(
        self.val_dataset,
        batch_size=self.batch_size,
        num_workers=self.num_workers,
        pin_memory=True,
        shuffle=False,
```

```
def create dataloaders(
   data dir: str,
   batch size: int,
   num workers: int
   training data = datasets.MNIST(
        root=data dir,
        train=True,
        download=True,
        transform=ToTensor(),
   test data = datasets.MNIST(
        root=data dir,
        train=False,
        download=True,
        transform=ToTensor(),
   train dataloader = DataLoader(
        training data,
        batch size=batch size,
        shuffle=True,
        num workers=num workers,
        pin memory=True,
        persistent_workers=True)
   test dataloader = DataLoader(
        test data,
        batch size=batch size,
        shuffle=False)
   return train dataloader, test dataloader
```

```
class MNISTDataModule(L.LightningDataModule):
  def __init__(self, data_dir: str, batch_size: int, num_workers: int):
     super().__init__()
     self.data_dir = data_dir
     self.batch_size = batch_size
     self.num_workers = num_workers
  def prepare_data(self):
     datasets.MNIST(root=self.data_dir, train=True, download=True)
     datasets.MNIST(root=self.data_dir, train=False, download=True)
  def setup(self, stage=None):
     if stage == "fit" or stage is None:
        self.train_dataset = datasets.MNIST(
           root=self.data_dir, train=True, transform=ToTensor()
        self.val_dataset = datasets.MNIST(
           root=self.data_dir, train=False, transform=ToTensor()
  def train_dataloader(self):
     return DataLoader(
        self.train_dataset,
        batch_size=self.batch_size,
        num_workers=self.num_workers,
        pin_memorv=True.
        persistent_workers=True,
        shuffle=True,
  def val_dataloader(self):
     return DataLoader(
        self.val_dataset,
        batch_size=self.batch_size,
        num_workers=self.num_workers,
        pin_memory=True,
        shuffle=False,
```

```
class LeNet5(torch.nn.Module):
    def __init__(self):
        super(LeNet5, self). init ()
        self.feature extractor = torch.nn.Sequential(
            torch.nn.Conv2d(
                in channels=1, out channels=6, kernel size=5,
            padding=2),
            torch.nn.ReLU(),
           torch.nn.MaxPool2d(kernel size=2, stride=2),
           torch.nn.Conv2d(
                in channels=6, out channels=16,
           kernel size=5),
           torch.nn.ReLU(),
           torch.nn.MaxPool2d(kernel size=2, stride=2)
        self.classifier = torch.nn.Sequential(
            torch.nn.Flatten(1),
           torch.nn.Linear(16*5*5, 120),
            torch.nn.ReLU(),
           torch.nn.Linear(120, 84),
           torch.nn.ReLU(),
           torch.nn.Linear(84, 10)
   def forward(self, x):
       x = self.feature extractor(x)
       x = self.classifier(x)
        return x
```

```
class LeNet5(L.LightningModule):
   def __init__(self):
   def forward(self, x):
   def training step(self, batch, batch idx):
       x, y = batch
       y hat = self(x)
       loss = torch.nn.functional.cross_entropy(y_hat, y)
        self.log("train loss", loss)
        return loss
   def validation step(self, batch, batch idx):
       x, y = batch
       y hat = self(x)
       loss = torch.nn.functional.cross entropy(y hat, y)
       self.log("val loss", loss, prog bar=True)
       self.log("val acc", (y hat.argmax(1) ==
                y).float().mean(), prog bar=True)
        return loss
   def configure optimizers(self):
       return torch.optim.Adam(self.parameters(), lr=0.001)
```

```
def main(batchsize: int, epochs: int, workers: int, force_cpu: bool):
   torch.manual seed(42)
   torch.backends.cudnn.benchmark = True
   device = 'cuda' if torch.cuda.is available() and not force cpu else 'cpu'
   train_dataloader, test_dataloader = create_dataloaders(
        '../data', batchsize, workers)
   lenet5 = LeNet5()
   lenet5.to(device)
   loss fn = torch.nn.CrossEntropyLoss()
   optimizer = torch.optim.SGD(params=lenet5.parameters(), lr=0.1)
   train time start on cpu = timer()
   for epoch in range(epochs):
        with tqdm(train_dataloader, desc=f'{epoch=}', unit='batch') as tepoch:
           train loss = train step(lenet5, tepoch, loss fn, optimizer, device)
           test_loss, test_acc = test_step(
                lenet5, loss fn, test dataloader, device)
           # Print out what's happening
            print(
               f"Train loss: {train loss:.5f} | Test loss: {test loss:.5f}, Test
acc: {test acc*100:.4f}%")
```

- Outras vantagens do Lightning
 - Já implementa TQDM (podemos customizar)
 - Controla log de métricas e loss
 - Controla checkpoints


- Outras vantagens do Lightning
 - Já implementa TQDM (podemos customizar)
 - Controla log de métricas e loss
 - Controla checkpoints
 - Integra com diferentes plataformas de MLOps
 - Facilita treinamento distribuído

Log de Experimentos

- Para acompanhar experimentos e tomar decisões de projeto é interessante realizar log e acompanhar as métricas do modelo
- Existem diversas ferramentas que permitem tal abordagem, vamos falar de duas delas
 - Tensorboard
 - wandb


Tensorboard

- É a ferramenta padrão de monitoramento de treinamento de modelos
- Possibilita logar imagens, áudio, métricas, histogramas para diversos experimentos



wandb

- É uma plataforma online com diversas funcionalidades para log e acompanhamento de experimentos
- Permite geração de relatórios online para compartilhamento de informações
- Possibilita otimização de hiperparâmetros usando "sweeps"
 - Inclusive em máquinas diferentes



Referências

- https://lightning.ai/docs/pytorch/stable/
- https://wandb.ai