

 PUCRS	Aprendizado Profundo II
	Professores: Lucas Silveira Kupssinskü e Otávio Parraga
	Prova 1

- 1) (2.5) *Normalizing Flows* são modelos geradores baseados em transformações invertíveis que mapeiam uma distribuição simples (como uma Gaussiana) para uma distribuição mais complexa por meio de uma sequência de funções bijetoras, geralmente parametrizadas por redes neurais.
 - a. (1.0) Por que um MLP não pode ser considerado um *flow*? Qual a vantagem de utilizarmos *flows* ao invés de funções arbitrárias para modelar geração de instâncias e modelagem de distribuições de probabilidade?
 - b. (1.5) Defina um *flow* linear, represente os pesos, mostre uma computação *forward* e uma computação *inverse*.

- 2) Em modelos do tipo Variational Autoencoder (VAE), é comum demonstrar que a transição entre dois pontos do espaço latente resulta em uma mudança suave nas amostras geradas. Para ilustrar essa transição, podemos interpolar entre dois vetores do espaço latente usando diferentes técnicas.
 Duas opções são a interpolação linear simples e a interpolação linear esférica. No entanto, em muitos casos, a interpolação esférica é preferida.
 - a. (1.0) Explique por que a interpolação linear esférica é mais adequada do que a interpolação linear simples ao transitar entre dois pontos no espaço latente de um VAE. Fundamente sua resposta com base na geometria do espaço latente e no comportamento esperado do modelo.
 - b. (0.5) Mostre as fórmulas de cada tipo de interpolação.
 - c. (1.0) Aplique ambas para interpolar entre dois vetores de exemplo e esboce um gráfico comparando os caminhos percorridos pelas duas técnicas no espaço vetorial (pode ser em 2D para simplificação).

- 3) Para podermos distribuir um ChatBot baseado em LLM, diversas são as etapas envolvidas no treinamento. Dessa forma, três são os principais momentos: pré-treino, instruction-tuning e alinhamento.
 - a. (1.0) Detalhe cada etapa do fluxo, apontando e exemplificando corpus para treinamento, qual ou quais funções de custo são utilizadas em cada etapa, quais vieses e comportamentos são aprendidos e “removidos” com cada etapa e quais os custos computacionais envolvidos.
 - b. (0.5) Por que chamamos o processo de instruction-tuning de “Supervised Fine-Tuning” (SFT)?
 - c. (1.0) Compare os processos de RLHF e DPO, apresente as funções de custo, analise os termos presentes e discuta as vantagens e desvantagens de cada abordagem.

 PUCRS	Aprendizado Profundo II
	Professores: Lucas Silveira Kupssinskü e Otávio Parraga
	Prova 1

- 4) (1.0) Temos diversas alternativas para o que chamamos de Parameter Efficient Fine Tuning (PEFT)
 - a. (0.5) Explique como funciona o treinamento com Mixed-Precision e especifique quais os problemas que impedem o treinamento inteiro em precisão f16.
 - b. (0.5) Considerando a abordagem LoRA, detalhe quais os benefícios durante o fine-tuning e explique se é recomendado usar essa abordagem durante o pré-treino do modelo.

- 5) Modelos multimodais como o CLIP alinham representações textuais e de imagem em um único espaço vetorial compartilhado.
 - a. (1.0) Descreva a arquitetura do CLIP e apresente a função de custo do modelo. Explique por que chamamos o treinamento de contrastivo e qual o efeito da função de custo nos modelos de encoder.
 - b. (0.5) Descreva e exemplifique como fazemos para trabalhar com classificação de imagens zero-shot.